

Location Analysis for DRT Services in Gyeonggi Province

- **Deriving New Service Zones Using a PySpark-Based Machine Learning Classification Model**

Industrial Engineering NayeongPark
Industrial Engineering JunhaWon

2026. 06.


1. Introduction

1.1 Background

똑버스는 경기도가 대중교통 취약지역의 이동권을 보장하기 위해 도입한 수요응답형 교통서비스(DRT: Demand Responsive Transit)이다. 이는 정 노선이 아닌 수요에 따라 탄력적으로 운행된다는 점에서 기존 시내 및 농어촌버스와 차별화된다[1]. 특히, 통계청에 따르면 경기도의 65세 이상 고령 인구 비율은 2020년 13.2%에서 2026년 4월 기준 18.2%로 급증하며 초고령사회 진입의 컷오프인 20%를 목전에 두고 있다[2]. 이는 보행 거리와 환승 부담이 큰 노년층에게 더욱 유연한 교통수단의 필요성이 커지고 있음을 보여준다. 이러한 점에서 똑버스는 단순한 이동 수단을 넘어, 대중교통 접근성이 낮은 주민과 고령층의 생활권 이동을 지원하는 정책 수단으로서 의미가 크다.

똑버스는 경기교통공사가 운영하는 통합교통플랫폼 '똑타' 앱을 통해 이용할 수 있으며, 이용자는 앱에서 출발지와 목적지, 탑승 인원을 입력한 뒤 차량을 호출하면 된다. 호출 후에는 안내된 승차정류소와 도착 예정 시간을 확인한 다음 해당 위치로 이동해 탑승하면 되며, 탑승 시에는 차량번호와 좌석을 확인하고 등록된 교통카드로 결제한다. 요금은 일반 시내버스와 같은 수준으로, 성인은 1,450원이며 청소년은 1,010원, 어린이는 730원이고 수도권 통합 환승할인이 적용된다[3]. 따라서 똑버스는 별도의 복잡한 절차 없이 스마트폰 앱과 교통카드만 있으면 이용할 수 있는 생활밀착형 교통서비스라는 특징을 가진다.

다만 똑버스는 경기도 내 모든 지역에서 자유롭게 이용할 수 있는 서비스가 아니라, 일정한 서비스 구역으로 지정된 곳에서만 호출과 운행을 할 수 있다는 제약이 있다. 즉, 같은 시군 안에서도 서비스 구역 포함 여부에 따라 주민의 실제 이용 가능성이 달라질 수 있으며, 결국 구역 설정 방식은 서비스 형평성과 접근성에 직접적인 영향을 미친다. [그림 1]은 이러한 똑버스 서비스 구역의 예시를 보여주며, 파란 테두리로 표시된 구역 내에서만 차량 호출이 가능하다는 점을 확인할 수 있다.



[그림 1] 똑버스 서비스 구역 예시 (파란 테두리 내 구역에서만 차량 호출 가능)

이러한 한계를 보완하기 위해 최근 경기도는 실제 똑버스 운행 데이터를 분석하여 배차를 개선하

고, 도내 서비스 지역을 점진적으로 확대해 나가고 있다.[4][5] 경기도의 이러한 정책 방향은 똑버스가 단순한 교통수단을 넘어, 교통취약자의 이동 공백을 줄이고 도민의 생활권 이동권을 보장하는 수단으로 활용되고 있음을 보여준다. 따라서 앞으로는 어떤 지역에 똑버스를 우선적으로 배치할 것인지에 대한 데이터 기반의 객관적인 검토가 필요하다.

1.2 Purpose

본 프로젝트의 목적은 기존 똑버스 설치 지역의 입지 특성을 학습하여, 현재 똑버스가 운행되지 않는 경기도 내 1km × 1km 격자 중 신규 서비스 도입 가능성이 높은 후보지를 도출하는 것이다. 이를 위해 고령 인구, 생활편의시설, 의료·복지시설, 버스정류장, 기업체 및 공장 등 지역 특성 변수를 격자 단위로 통합하고, XGBoost 기반 이진 분류 모델을 활용하여 각 미설치 격자의 서비스 가능성 확률을 산출하였다.

최종적으로는 단순히 예측 확률이 높은 지역을 나열하는 데 그치지 않고, 기존 설치 지역과의 거리, 주변 고확률 격자의 군집성, 실제 위성지도 기반 주변 환경을 함께 고려하여 정책적으로 검토 가능한 신규 똑버스 권역 후보지를 제안하고자 한다.

2. Main Idea

2.1 Source Data

본 분석은 경기도 전체를 1km × 1km 격자 단위로 나누고, 각 격자에 포함되는 공공데이터 기반 시설 및 인구 변수를 집계하는 방식으로 수행하였다. 최종 분석에 사용된 데이터셋은 전처리 완료 후 MyDrive/hdfs_final_data.csv 형태로 저장하였으며, 각 행은 하나의 격자를 의미한다.

Dataset	Feature	Source
전체 경기도 1km × 1km 격자	GRID_CD, geometry	국토정보플랫폼
경기도 고령 인구 데이터	senior_population	공공데이터 기반 집계
행정복지센터 현황	new_village	공공데이터포털
노인여가복지시설 현황	senior_center	경기도데이터드림
병원·약국 현황	medical, pharmacy	경기도데이터드림
시장·마트 및 음식점 현황	market, restaurant	경기도데이터드림
버스정류소 현황	bus_station	경기도데이터드림
업무시설·사업체·공장 현황	service_facility, enterprise, factory	경기도데이터드림
똑버스 운행 여부	bus / 운행대수	경기교통공사 기반 정리

[표 1] 분석 데이터 및 변수 구성

2.2 Data Preprocessing

2.2.1 Environment Setup

```
(base) PS C:\Users\박나영> wsl -l -v
NAME                STATE              VERSION
* Ubuntu            Stopped            2
  spark-pseudomaster Stopped            2
(base) PS C:\Users\박나영> wsl -d spark-pseudomaster
[sudo] password for ubuntu:
ubuntu-master IP (172.24.181.200)
(pyspark_env) ubuntu@ubuntu-master:~/start/hadoop$ |
```

[그림 2] spark-pseudomaster 배포판 실행

```
# 1. 전체 중지
stop-all.sh

# 2. 임시 파일만 삭제
rm -rf /tmp/hadoop-ubuntu

# 3. datanode VERSION을 namenode clusterID에 맞춤
sudo sed -i 's/clusterID=.*clusterID=CID-d785fcba-73f9-4a95-b6fa-a72d1292288f/' /data/HDFS/datanode/current/VERSION

# 4. 재시작
start-all.sh
hadoop dfsadmin -safemode leave

# 5. 확인
jps
```

[그림 3] .Go 스크립트

PySpark 기반 데이터분석을 위해 Window PowerShell에서 'spark-pseudomaster' 가상환경을 import 하여 진행하였다. 기존의 .Go(초기 실행 스크립트)를 실행할 때 Datanode가 비정상 종료되는 문제가 발생하였고, 아래와 같은 코드를 포함하여 .Go 파일의 스크립트를 수정하였다. 그러나 수정 이후에도 format 명령어로 인해 Hadoop 재시작 시, HDFS에 적재해 두었던 파일 및 사용자 디렉토리 (/user/ubuntu/Downloads)가 삭제되었고, 최종적으로 위 명령어들로 .Go 파일을 재구성하였다.

```
#stop-all.sh

#rm -rf /tmp/hadoop-ubuntu

#sudo rm -rf /data/HDFS/namenode/*

#sudo rm -rf /data/HDFS/datanode/*

#hdfs namenode -format

#start-all.sh
```

2.2.2 Data Collection and Loading

PySpark 환경의 Jupyter Notebook에서 한글 깨짐 없이 원천 데이터를 확인하고 전처리하기 위해 모든 CSV 파일을 UTF-8 인코딩으로 변환하였다. 격자 생성에 사용되는 SHP 파일의 경우, 한글로 된 파일명을 영문으로 변경하여 HDFS 적재 시 발생할 수 있는 인코딩 오류를 사전에 방지하였다. 최종적으로 529MB (555,406,122 바이트)의 데이터를 적재하였다.

```
ubuntu@ubuntu-master:~/start/hadoop$ cp /mnt/c/Users/박나영/Desktop/hdfs/raw_data/* ~/Downloads
ubuntu@ubuntu-master:~/start/hadoop$ ls ~/Downloads
bus_station.csv      grid_daba_1K.shx    grid_laba_1K.prj    polulation1.csv
drt_bus.csv          grid_dasa_1K.cpg    grid_laba_1K.shp    population2.csv
enterprise.csv       grid_dasa_1K.dbf    grid_laba_1K.shx    population3.csv
factory.csv          grid_dasa_1K.prj    grid_lasa_1K.cpg    population4.csv
grid_daa_1K.cpg      grid_dasa_1K.shp    grid_lasa_1K.dbf    population5.csv
grid_daa_1K.dbf      grid_dasa_1K.shx    grid_lasa_1K.prj    population6.csv
grid_daa_1K.prj      grid_laa_1K.cpg     grid_lasa_1K.shp    restaurant.csv
grid_daa_1K.shp      grid_laa_1K.dbf     grid_lasa_1K.shx    senior_center.csv
grid_daa_1K.shx      grid_laa_1K.prj     hadoop-3.5.0.tar.gz service_facility.csv
grid_daba_1K.cpg     grid_laa_1K.shp    market.csv          spark-4.1.1-bin-hadoop3.tgz
grid_daba_1K.dbf     grid_laa_1K.shx    medical.csv
grid_daba_1K.prj     grid_laba_1K.cpg    new_village.csv
grid_daba_1K.shp     grid_laba_1K.dbf    pharmacy.csv
```

[그림 4] spark-pseudomaster 환경에 로컬 데이터 복사

```
ubuntu@ubuntu-master:~/start/hadoop$ hdfs dfs -put ~/Downloads/* /user/ubuntu/Downloads
2026-06-08 19:26:25,270 INFO Configuration.deprecation: dfs.permissions in hdfs-site.xml is deprecate
ed. Instead, use dfs.permissions.enabled
2026-06-08 19:26:25,888 INFO Configuration.deprecation: dfs.permissions in hdfs-site.xml is deprecate
ed. Instead, use dfs.permissions.enabled
2026-06-08 19:26:26,164 INFO Configuration.deprecation: dfs.permissions in hdfs-site.xml is deprecate
ed. Instead, use dfs.permissions.enabled
2026-06-08 19:26:26,300 INFO Configuration.deprecation: dfs.permissions in hdfs-site.xml is deprecate
ed. Instead, use dfs.permissions.enabled
2026-06-08 19:26:46,506 INFO Configuration.deprecation: dfs.permissions in hdfs-site.xml is deprecate
ed. Instead, use dfs.permissions.enabled
ubuntu@ubuntu-master:~/start/hadoop$ hdfs dfs -ls /user/ubuntu/Downloads
2026-06-08 19:27:04,408 INFO Configuration.deprecation: dfs.permissions in hdfs-site.xml is deprecate
ed. Instead, use dfs.permissions.enabled
2026-06-08 19:27:04,944 INFO Configuration.deprecation: dfs.permissions in hdfs-site.xml is deprecate
ed. Instead, use dfs.permissions.enabled
Found 49 items
-rw-r--r-- 3 ubuntu supergroup 4895650 2026-06-08 19:26 /user/ubuntu/Downloads/bus_station.csv
-rw-r--r-- 3 ubuntu supergroup 20639 2026-06-08 19:26 /user/ubuntu/Downloads/drt_bus.csv
-rw-r--r-- 3 ubuntu supergroup 344397481 2026-06-08 19:26 /user/ubuntu/Downloads/enterprise.csv
-rw-r--r-- 3 ubuntu supergroup 28699486 2026-06-08 19:26 /user/ubuntu/Downloads/factory.csv
```

[그림 5] HDFS에 spark-pseudomaster의 데이터 적재

2.2.3 PySpark-Based Preprocessing

▀ 좌표 변환

```
ubuntu@ubuntu-master:~/start/hadoop$ source ~/pyspark_env/bin/activate
(pyspark_env) ubuntu@ubuntu-master:~/start/hadoop$ pyspark
```

[그림 6] Pyspark 실행

The screenshot shows a Jupyter Notebook titled 'dataload' with a last checkpoint of 5 days ago. The interface includes a file browser on the left and a code editor on the right. The code editor contains a Python script that runs an HDFS command to list files in a specific directory. The output of the command is displayed below the code cell.

```
[9]: import subprocess
result = subprocess.run(
    ["hdfs", "dfs", "-ls", "/user/ubuntu/Downloads"],
    capture_output=True, text=True
)
print(result.stdout)
```

```
Found 47 items
-rw-r--r-- 3 ubuntu supergroup 4895650 2026-06-03 14:37 /user/ubuntu/Downloads/bus_station.csv
-rw-r--r-- 3 ubuntu supergroup 20639 2026-06-03 14:38 /user/ubuntu/Downloads/drt_bus.csv
```

[그림 7] Jupyter Notebook

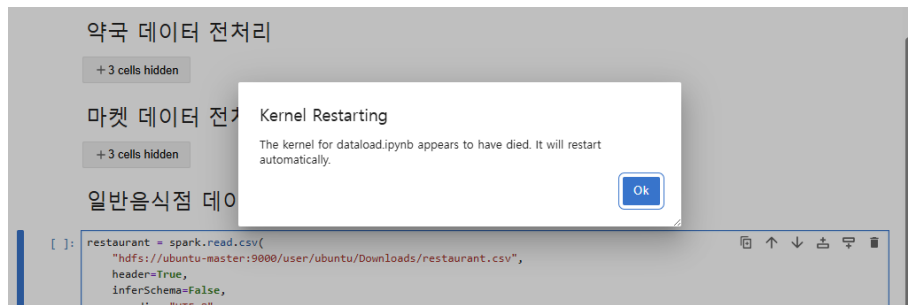
연번	시도	시군구	읍면동	우편번호	주소	latitude	longitude
[1199]	경기	김포시	통진읍 행정복지센터	10019	경기도 김포시 통진읍 마송1로 77	37.6866731914427	126.600048757971
[1200]	경기	김포시	고촌읍 행정복지센터	10129	경기도 김포시 고촌읍 장차로 14	37.6033046472851	126.770949050148
[1201]	경기	김포시	양촌읍 행정복지센터	10057	경기도 김포시 양촌읍 양곡1로 6...	37.6572011427027	126.625431221903
[1202]	경기	김포시	대곶면 행정복지센터	10040	경기 김포시 대곶면 월생로 83-23	37.649110463461	126.581959491405
[1203]	경기	김포시	월곶면 행정복지센터	10024	경기도 김포시 월곶면 군하로 263	37.7151376836215	126.55284251058

[그림 8] Jupyter Notebook에서 전처리 진행

HDFS에 적재된 각 파일을 Jupyter Notebook에서 순차적으로 열어 위도·경도 컬럼의 존재 여부를 확인하였다. 이후 경기도 격자와의 매핑 작업을 원활히 수행하기 위해 모든 파일의 위도·경도 컬럼명을 'latitude'와 'longitude'로 통일하는 전처리를 진행하였다. 일부 파일에는 위도·경도 정보 없이 주소 데이터만 존재하였다. 해당 파일에 대해서는 Kakao Developers의 '주소로 좌표 변환' API를 활용하여 주소를 위도·경도로 변환하는 전처리를 수행하였다.

▪ 원천 데이터 전처리

본 분석에 사용된 데이터는 소규모로, Spark DataFrame만으로도 전처리가 가능하였다. 그러나 Pandas에 비해 Spark DataFrame의 속련도가 부족하여 spark.read.csv로 읽어 들인 후 Pandas로 변환하는 방식을 채택하였다. 이는 본 프로젝트의 한계점으로, 향후 Spark DataFrame을 활용한 전처리로 개선할 여지가 있다.



[그림 9] OOM 발생

HDFS에 적재한 파일 중 14MB 규모의 일반음식점 CSV 파일 처리할 때 OOM(Out of Memory) 오류가 발생하였다. Java 기반인 Spark는 데이터 규모와 무관하게 기본적으로 2~3GB의 메모리를 사용하며, 실행 환경의 RAM이 8GB·CPU가 4코어로 제한적인 상황에서 의사분산모드로 실행 중인 가상 환경이 이를 감당하지 못한 것으로 판단된다. Pandas로 직접 읽어 들이는 때에도 동일한 문제가 발생해, 이후 전처리 작업만 Google Colab 환경으로 전환하여 진행하였다.


타깃 변수인 운행 대수는 신규 서비스 권역 도출이라는 목적에 맞추어 이진 변수로 변환하였다. 운행 대수가 1대 이상인 격자는 기존 설치 지역(bus=1), 운행대수가 0인 격자는 미설치 지역(bus=0)으로 정의하였다.

▪ 1km x 1km 격자 생성


본 분석의 공간 단위는 행정동이 아닌 1km × 1km 격자로 설정하였다. Spark는 SHP 파일 형식을 기본 지원하지 않으므로, 격자 생성에 필요한 SHP 파일은 GeoPandas로 읽어 들였다.

경기도 범위에 한정된 격자 데이터가 존재하지 않아, 대한민국 전체 시도·시군구·읍면동 경계 데이


터를 제공하는 오픈소스 GitHub 레포지토리(southkorea-maps)의 GeoJSON 파일을 URL로 불러와 전국 1km × 1km 격자 데이터에서 경기도 해당 격자만을 추출하였다. 이후 앞서 전처리한 데이터를 위도·경도 기준으로 격자에 매핑하고, 격자별 고령 인구 수, 버스정류장 수, 병원·약국 수, 음식점 수, 기업체 및 공장 수를 집계하였다. 전체 경기도 격자와 독버스 운행 구역 격자는 아래와 같다.



[그림 10] 전체 경기도 격자




[그림 11] 독버스 운행 구역 격자




[그림 12] 모든 피쳐 값이 0인 격자


[그림 12]는 전체 격자 10,847개 중 모든 피쳐 값이 0인 1,986개의 격자를 시각화한 것이다. 아래 사진과 같이 해당 격자는 비무장지대(DMZ), 해안, 산지 등 실질적인 생활권 외 지역에 해당함을 확인하였으며, 별도의 추가 전처리 없이 분석을 진행하였다.



[그림 13] 비무장지대(DMZ)



[그림 14] 해안



[그림 15] 산지

2.2 Datamining Process

모델링 단계에서는 기존 설치 지역과 미설치 지역의 지역 특성 차이를 학습하기 위해 XGBoost 분류 모델을 적용하였다. XGBoost는 Gradient Boosting 기반의 Tree 앙상블 모델로, 여러 개의 Decision Tree를 순차적으로 학습하면서 이전 단계의 오차를 보완한다. 본 분석에서는 각 격자 (i)의 특성 벡터 (X_i)를 입력으로 하여 $P(\text{bus}_i = 1|X_i)$, 즉 해당 격자가 기존 독버스 설치 지역과 유사한 특성을 가질 확률을 산출하였다.

본 분석에서 XGBoost를 최종 모델로 선택한 이유는 크게 세 가지이다. 첫째, XGBoost는 Tree 기반 모델이기 때문에 고령 인구, 버스정류장 수, 음식점 수, 기업체 수, 공장 수와 같은 지역 특성 변수가 예측에 어떻게 작용했는지 비교적 직관적으로 해석할 수 있다. 즉, 단순히 예측 확률만 산출하는 것이 아니라 Feature Importance를 통해 어떤 입지 요인이 독버스 설치 지역과의 유사성 판단에 영향을 주었는지 확인할 수 있다는 장점이 있다. 둘째, Boosting 기반 모델은 이전 단계에서 잘못 분류된 관측치에 더 집중하면서 순차적으로 모델을 개선하기 때문에, 본 분석처럼 1km × 1km 격자 단위로 유사한 특성을 가진 지역 데이터가 다수 존재하는 경우에도 세밀한 차이를 학습하는 데 효과적이다. 셋째, XGBoost는 여러 개의 Decision Tree를 결합하는 앙상블 모델이므로 단일 Tree 모델보다 과적합 위험을 줄이면서도 비선형 관계와 변수 간 상호작용을 반영할 수 있다. 따라서 본 분석에서는 예측 성능과 해석 가능성을 동시에 확보할 수 있는 모델로 XGBoost를 활용하였다.

시각화 단계에서는 예측 결과를 지도 기반으로 표현하였다. 기존 설치 지역은 하늘색으로 표시하고, 미설치 후보 지역은 모델의 예측 확률인 XGBoost predict_proba 값에 따라 0.2 단위의 5개 구간으로 나누어 빨간색 농도를 다르게 적용하였다. 이를 통해 경기도 전체에서 신규 서비스 확장 가능성이 높은 지역을 직관적으로 파악할 수 있도록 하였다.

2.3 Program Design & Implementation

Step	Process	Description
Step 1	XGBoost 모델 학습	고령 인구, 복지시설, 의료시설, 음식점, 정류장, 기업체, 공장 등의 수치형 변수를 이용해 이진 분류 모델을 학습한다.
Step 2	후보지 확률 산출	전체 격자에 대해 predict_proba를 계산한 뒤, bus=0인 미설치 지역만 따로 추출하여 확률 기준으로 정렬한다.
Step 3	지도 시각화	기존 설치 지역은 하늘색, 미설치 후보 지역은 예측 확률 구간별 빨간색 농도로 표시한다.
Step 4	최종 후보지 선정	상위 확률, 기존 설치 지역과의 거리, 주변 고확률 격자 밀집도, 위성지도 기반 실제 환경을 종합적으로 고려한다.

[표 2] 프로그램 설계 및 구현 흐름

본 프로젝트에서 사용하는 모델은 지도학습 기반 분류모델로 Spark MLlib의 XGBoost를 사용하였다. 이를 위해 xgboost 패키지와 sklearn을 추가적으로 설치하여 분석을 진행하였다.


```
[2]: #pip install xgboost --break-system-packages
```

```
[3]: #pip install scikit-learn --break-system-packages
```

[그림 16] 사용된 패키지

```
+-----+
| GRID_CD|geometry|senior_population|new_village|senior_center|medical|pharmacy|market|restaurant|bus_station|service_facility|enterprise|factory|
|운행대수|
+-----+
|다아3700|POLYGON ((126.782...|0.0|0|0|0|0|0|0|0|0|0|0|
|0|
|다아3800|POLYGON ((126.793...|0.0|0|0|0|0|0|0|0|0|0|0|
|0|
|다아3900|POLYGON ((126.805...|0.0|0|0|0|0|0|0|0|0|0|0|
|0|
|다아4000|POLYGON ((126.816...|0.0|0|0|0|0|0|0|0|0|0|0|
|0|
|다아4001|POLYGON ((126.816...|0.0|0|0|0|0|0|0|0|0|0|0|
|0|
+-----+
```

[그림 17] 전처리 완료 후 최종 데이터셋

```
사용 Feature
['senior_population', 'new_village', 'senior_center', 'medical', 'pharmacy', 'market', 'restaurant', 'bus_station', 'service_facility', 'enterprise',
'factory']
+-----+
| GRID_CD|bus|predict_proba|
+-----+
|다아3700|0|0.16862502694129944|
|다아3800|0|0.16862502694129944|
|다아3900|0|0.16862502694129944|
|다아4000|0|0.16862502694129944|
|다아4001|0|0.16862502694129944|
+-----+
only showing top 5 rows
```

[그림 18] 모델의 predict_proba

2.4 Model Test Result

모델의 성능은 전체 격자를 학습-검증 데이터로 분할하여 확인하였다. 본 분석의 핵심 목적은 기존 설치 지역을 완벽하게 분류하는 것이 아니라, 미설치 지역 중 기존 설치 지역과 유사한 입지 특성을 가진 후보지를 확률 순위로 선별하는 것이다. 따라서 모델 성능은 분류 정확도와 함께 예측 확률 기반 후보지 ranking 결과를 중심으로 해석하였다.

Metric	Value	Interpretation
Accuracy	0.7866	전체 검증 데이터 중 올바르게 분류된 비율
Precision	0.7756	설치 지역으로 예측한 격자 중 실제 설치 지역의 비율
Recall	0.7865	실제 설치 지역 중 모델이 설치 지역으로 포착한 비율
F1-score	0.7291	Precision과 Recall의 조화평균
ROC-AUC	0.6614	확률 기반 순위 구분 성능

[표 3] XGBoost 모델 검증 결과

전체 검증 데이터 중 올바르게 분류된 비율을 나타내는 모델 평가지표인 Accuracy는 0.7866으로 상당히 우수한 결과가 도출되었다. 이로 인해, 우리 모델의 결과가 실제로 의미를 갖는다는 당위성을 확보하였다.

Feature	Importance
고령인구	0.1943
기업체	0.1462
공장	0.1135
경로당	0.1130
버스정류장	0.0839
식당	0.0779
노인여가복지시설	0.0664
약국	0.0558
병원	0.0511
시장	0.0499
마을회관	0.0483

[표 4] XGBoost Feature Importance


똑버스 운행에 각 변수 별로 끼친 영향을 나타내는 지표인 Feature Importance를 확인한 결과, 고령 인구, 기업체 수, 공장 수, 경로당 수, 버스정류장 수 등이 주요 변수로 나타났다. 이는 똑버스 입지 판단이 단순히 인구 규모만으로 결정되는 것이 아니라, 고령층 생활 이동 수요와 산업·생활시설 기반 이동 수요가 함께 반영되는 문제임을 보여준다.

2.5 Prediction & Visualization Result

아래 지도는 경기도 전체 1km × 1km 격자를 대상으로 XGBoost 예측 결과를 시각화한 것이다. 하늘색 격자는 기존 똑버스 설치 지역이며, 빨간색 격자는 미설치 지역 중 신규 도입 가능성이 예측된 지역이다. 빨간색이 진할수록 기존 설치 지역과 유사한 특성을 가지는 지역으로 표현했다.

순위	GRID_CD	예측확률	고령인구	경로당	음식점	정류장	기업체	공장
1	다사7351	0.8879	9955	4	219	4	0	0
2	다사7563	0.8678	0	0	0	0	33	10
3	다사7928	0.8600	0	0	0	0	20	3
4	다사6582	0.8545	0	0	13	3	13	3
5	다바7987	0.8444	0	3	33	4	205	3
6	다사5991	0.8108	0	0	1	2	5	4
7	다사3027	0.7778	20	0	3	13	639	475
8	다사6945	0.7631	7299	9	100	2	0	0
9	다사6296	0.7610	0	0	2	3	18	2
10	다바7988	0.7499	0	1	18	2	147	0

[표 5] XGBoost predict_proba 기준 미설치 후보 지역 TOP 10



[그림 19] 경기도 전체 톡버스 신규 후보 지역 예측 결과

예측 결과, predict_proba가 0.8 이상으로 나타난 상위 6개 격자가 우선 검토 후보지로 도출되었다. 이들 지역은 모델이 기존 톡버스 설치 지역과 유사한 입지 특성을 가진다고 판단한 곳으로, 신규 권역 설정 시 우선적으로 검토할 필요가 있다.

다만 실제 신규 권역은 하나의 격자만으로 결정되기 어렵다. 따라서 본 분석에서는 상위 후보 격자의 예측 확률뿐만 아니라 기존 설치 지역과의 거리, 주변 고확률 격자의 밀집 여부, 실제 주변 환경을 함께 검토하였다. 그 결과 기존 설치 지역과 일정 거리가 있으면서도 인접 격자에서 높은 예측 확률이 반복적으로 나타나는 두 개의 군집형 후보지를 최종 검토 지역으로 선정하였다. 본 보고서에서는 이를 각각 Fig. 1과 Fig. 2로 명명하였다.

2.6 Final Candidate Site Analysis

최종 후보지는 단순한 통계적 확률값만으로 판단하지 않고, 위성지도 기반 입지 주변 환경을 함께 확인하였다. 이는 실제 서비스 권역을 설정할 때 지형, 시설 분포, 기존 교통망, 생활권 단절 여부 등이 함께 고려되어야 하기 때문이다.



[그림 20] Fig. 1 후보지의 위성지도 기반 입지 주변 환경



[그림 21] Fig. 2 후보지의 위성지도 기반 입지 주변 환경

Fig. 1은 고령 인구 규모가 크고, 주변에 노인 관련 시설 및 생활편의시설이 비교적 풍부하게 분포한 지역이다. 해당 권역 주변에는 병원, 음식점 등 생활 기반 시설이 함께 위치하고 있어 고령층의 단거리 생활 이동 수요가 발생할 가능성이 높다. 따라서 기존 대중교통 접근성이 충분하지 않은 경우, 독버스 도입을 통해 생활권 이동 편의를 개선할 수 있는 후보지로 판단된다.

Fig. 2는 산지와 산업·상업 시설이 혼재된 지역이다. 위성지도상에서 공장, 소규모 사업체, 점포가 산지 주변에 분산되어 있으며, 지형적 제약으로 인해 일반적인 정규 노선형 대중교통만으로는 세밀한 이동 수요를 충족하기 어려울 가능성이 있다. 특히 출퇴근 및 생활 이동 수요가 일정하게 존재하지만, 기존 교통망이 촘촘하게 연결되기 어려운 입지라는 점에서 독버스의 적용 가능성이 높다. 또한, 선정된 격자의 고령 인구수는 0이지만, 이는 해당 지역이 공업지구이기 때문이고, 데이터를 확인해보면 실제 거주는 위쪽 거주 지구에서 많이 이루어지는 것을 확인할 수 있었다.

3. Conclusion

본 프로젝트는 경기도 내 독버스 서비스의 신규 서비스 구역을 도출하는 입지분석이다. 공공기관으로부터 다운로드 받은 로컬 파일을 Ubuntu 환경에 복사하고, 이를 HDFS에 적재하였으며, Lab에서 제공된 Pseudo 모드 Hadoop Cluster 위에서 가동되는 PySpark 플랫폼에서 분석을 수행하였다.

본 프로젝트에서는 경기도 전체 1km × 1km 격자를 분석 단위로 설정하고, 기존 독버스 설치 지역의 입지 특성을 XGBoost 모델로 학습한 뒤, 미설치 지역 중 신규 서비스 도입 가능성이 높은 후보지를 도출하였다. 분석 결과 예측 확률이 0.8 이상인 상위 6개 격자가 우선 검토 후보지로 선별되

었으며, 이 중 기존 설치 지역과의 거리, 주변 고화률 격자의 군집성, 실제 위성지도 기반 주변 환경을 종합적으로 고려하여 Fig. 1과 Fig. 2를 최종 후보 권역으로 제안하였다.

Fig. 1은 고령 인구와 생활편의시설이 함께 분포하여 고령층 생활 이동 수요 대응에 적합한 지역이며, Fig. 2는 산지와 산업·상업시설이 혼재되어 정규 노선형 대중교통의 접근 한계가 발생하기 쉬운 지역이다. 따라서 두 지역은 제한된 권역 설정만으로도 교통 사각지대 보완, 고령층 이동 편의 개선, 산업·생활 이동 수요 대응 등의 효과를 기대할 수 있는 후보지로 판단된다.

결론적으로 본 분석은 신규 톡버스 권역 설정 문제를 단순한 행정구역 단위 판단이 아니라, 격자 단위 공간 데이터와 머신러닝 예측 확률을 결합한 데이터 기반 의사결정 문제로 접근했다는 점에서 의의가 있다. 향후 실제 정책 적용 단계에서는 현장 조사, 도로 폭 및 회차 가능성, 기존 버스 노선과의 중복성, 시간대별 이동 수요 데이터 등을 추가로 반영한다면 더욱 정교한 서비스 권역 설계가 가능할 것이다.

본 프로젝트를 통해 PySpark 환경에서의 전처리 작업이 실행 환경 구성에 크게 의존함을 직접 경험하였다. OOM 오류를 겪으며 클라우드 인프라가 제공하는 확장성과 안정성의 이점을 실감하였고, 아무리 잘 구성된 환경이라도 개인 장비의 성능적 한계를 완전히 극복하기는 어렵다는 점을 확인하였다. 이는 데이터 엔지니어링에서 코드의 완성도 못지않게 인프라 설계와 환경 최적화가 중요한 역량임을 보여준다. 또한, 단순히 공공데이터를 수집하고 시각화하는 수준을 넘어, 실제 정책 의사결정에 활용될 수 있는 형태로 데이터를 구조화하는 과정의 중요성을 확인할 수 있었다. 특히 행정동 단위가 아니라 $1\text{km} \times 1\text{km}$ 격자 단위로 데이터를 재구성하면서, 같은 시·군 안에서도 지역별 교통 수요와 시설 분포가 매우 다르게 나타날 수 있음을 확인하였다.

머신러닝 모델의 예측 결과를 그대로 최종 결론으로 사용하는 것은 한계가 있으며, 예측 확률, 공간적 군집성, 실제 주변 환경을 함께 해석해야 한다는 점을 배웠다. 모델은 후보지를 선별하는 도구로서 유용하지만, 최종 입지 선정에는 현장성과 정책적 타당성이 함께 고려되어야 한다. 이러한 점에서 본 프로젝트는 빅데이터 시스템, 공간 데이터 처리, 머신러닝 모델링, 지도 시각화가 하나의 문제 해결 흐름으로 연결되는 경험을 제공하였다.

4. References

- [1] 경기교통공사. (2026). *똑버스(수요응답형 교통수단) 사업소개*.
<https://www.gtrans.or.kr/web/lay1/S1T499C500/contents.do>
- [2] 통계청. (2026). *고령인구비율(시도/시/군/구)*. 국가통계포털.
https://kosis.kr/statHtml/statHtml.do?tblId=DT_1YL20631&orgId=101
- [3] 경기도교통정보센터. (2025, 6월 11일). *[경기도청] 10일부터 수원시 당수동 일대 '똑버스' 10대 운행 개시*. 경기도교통정보센터 교통소식.
<https://gits.gg.go.kr/web/newboard/3386.do?mode=view&schBcode=&schCon=&schStr=&schType=list&pageIndex=1&pageUnit=8&idx=197196488>
- [4] 경기도청. (2024). *경기도, 똑버스 데이터 분석해 배차 개선... 도정현안 해결에 AI·데이터 분석 적극 활용*. 경기도뉴스포털. 검색일자 2026년 6월 3일,
https://gnews.gg.go.kr/briefing/brief_gongbo_view.do?BS_CODE=S017&number=63572
- [5] 경기도교통정보센터. (2025, 10월 27일). *경기도, 27일 시흥 '똑버스' 개통. 20개 시군으로 확대 운행*. 검색일자 2026년 6월 3일,
<https://gits.gg.go.kr/web/newboard/3386.do?mode=view&schBcode=&schCon=&schStr=&schType=list&pageIndex=1&pageUnit=8&idx=198231481>

[요약]



1. 해결하고자 하는 문제

독버스: 경기도가 대중교통 취약지역의 이동권을 보장하기 위해 도입한 수요응답형 교통서비스

독버스는 모든 지역에서 호출할 수 있는 것이 아니라 서비스 권역이 지정되어 있는데, 어떤 지역을 권역으로 설정할지에 대한 명확한 기준이 존재하지 않는다. 따라서 기존 독버스 설치 지역의 입지 특성을 학습하여, 현재 독버스가 운행되지 않는 경기도 내 1km x 1km 격자 중 신규 서비스 도입 가능성이 높은 후보지를 도출하는 것이 목표이다.

2. 데이터 수집

csv+shp 파일 로컬에 저장 → Ubuntu 환경에 복사 → HDFS 적재 ⇒ PySpark 기반 전처리 환경 구성

Kernel Restarting

The kernel for dataload.ipynb appears to have died. It will restart automatically.

3. 데이터 전처리

spark.read.csv 데이터 읽어들이기 → .toPandas() 변환 → 전처리 수행



shp 파일로부터 1km x 1km 격자 생성 → 위도·경도 기준으로 각 격자에 매핑

⇒ 격자별 고령 인구 수, 버스정류장 수, 병원·약국 수, 음식점 수, 기업체 및 공장 수 집계

```

+-----+
| GRID_CD | geometry | senior_population | new_village | senior_center | medical | pharmacy | market | restaurant | bus_station | service_facility | enterprise | fact
ory |
+-----+
| [다]3700 | POLYGON ((126.782... | 0.0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 0 |
| [다]3800 | POLYGON ((126.793... | 0.0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 0 |
| [다]3900 | POLYGON ((126.805... | 0.0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 0 |
| [다]4000 | POLYGON ((126.816... | 0.0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 0 |
| [다]4001 | POLYGON ((126.816... | 0.0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 0 |
+-----+

```

4. 분석에 적용한 수학적 모델

2026-06-09 00:13:30.166 INFO XGBoost-PySpark: fit Finished xgboost training!

Spark MLlib의 SparkXGBClassifier 사용

HDFS가 데이터를 블록 단위로 분산 저장하고, Spark가 이를 파티션으로 읽어 들어 각 Worker에서 분산 처리하는 방식

여러 개의 약한 Decision Tree를 순차적으로 학습하면서 이전 트리가 틀린 오차를 다음 트리가 보완하는 방식으로 예측 성능을 높여가는 앙상블 모델

5. 분석 결과 (F1-score = 0.7291, Precision과 Recall의 변동성을 모두 반영한 안정적인 지표)

순위	GRID_CD	예측확률	고령인구	경로당	음식점	정류장	기업체	공장
1	다사7351	0.8879	9955	4	219	4	0	0
2	다사7563	0.8678	0	0	0	0	33	10

6. 도출한 결론 (똑버스 검토 지역 선정)

- Fig 1

고령인구 규모가 크고, 주변 생활편의시설 풍부
병원, 음식점 등 생활 기반 시설이 함께 위치
→ 고령층의 단거리 생활 수요가 발생할
가능성이 높다고 판단

- Fig 2

공장/소규모사업체/점포가 산지 주변에 분산
아래쪽은 공업지구, 위쪽은 거주지구 형태
→ 기존 교통망이 촘촘하게 연결되기 어려운
입지라고 판단

